UNIVERSIDAD CENTRAL

Facultad de Ingeniería y Ciencias Básicas Ingeniería

de Sistemas

Guía de repaso: segundo corte

19-Oct-2026

Ing. Elias Buitrago Bolivar

Realizado por Sergio David Vargas Garzón

Propósito. Repasar los conceptos del segundo corte mediante la revisión y explicación de procedimientos y resultados efectivamente desarrollados en los laboratorios de SECOP II y Spotify. Cada respuesta debe apoyarse en una evidencia del trabajo del equipo, no solamente en una definición teórica.

Dinámica de trabajo. Trabajen con el repositorio de GitHub de su equipo abierto. Para cada pregunta, busquen primero el procedimiento o resultado en los laboratorios de SECOP II o Spotify y expliquen lo que encontraron. Si no se desarrolló ese procedimiento (por ejemplo, una matriz de correlación), indíquenlo claramente y busquen la información necesaria para responder la pregunta. Después, expliquen cómo aplicarían el concepto a variables reales del conjunto de datos de su laboratorio. Distinguen en la respuesta lo que comprobaron en GitHub de lo que consultaron para complementar el análisis. No es necesario escribir código nuevo.

Registro de evidencias. Cuando encuentren el procedimiento, anoten el laboratorio (SECOP II o Spotify), el archivo o notebook, la sección o celda y el resultado observado. Si no está en el repositorio, escriban «No desarrollado en el laboratorio», indiquen qué fuente consultaron para comprenderlo y propongan su aplicación sobre columnas reales de sus datos. No presentan resultados hipotéticos como si hubieran sido obtenidos en el laboratorio ni se limiten a copiar definiciones o código.

Orientación para la búsqueda. Localizan en sus notebooks las operaciones de lectura y exploración inicial, revisión de calidad de datos, estadísticas descriptivas y visualizaciones. Los nombres de las secciones pueden variar entre equipos. Si no encuentran un procedimiento, no supongan que está implementado.

Conceptos relevantes

Los siguientes son algunos conceptos relevantes abordados durante el segundo corte, que pueden revisarse a partir de los laboratorios desarrollados:

1. Secuencia de un análisis exploratorio: inspección inicial, revisión de tipos, calidad de datos, estadísticas descriptivas, visualización e interpretación.
2. Estructura y perfilamiento de datos con pandas: lectura de un DataFrame, tipos de variables, `info()`, `describe()` y recuentos de valores únicos.
3. Tipos de datos y conversiones: variables numéricas, categóricas, fechas e identificadores; interpretación del tipo `object` y uso de `to_datetime()` cuando corresponda.
4. Calidad y preparación de datos: detección y tratamiento razonado de valores faltantes; identificación de registros duplicados y sus posibles efectos sobre el análisis.
5. Valores atípicos: cuartiles, rango intercuartílico (IQR), límites de la regla de Tukey e interpretación de un diagrama de caja (boxplot).

6. Estadística descriptiva: media, mediana, dispersión, desviación estándar y lectura crítica de distribuciones.
7. Selección e interpretación de visualizaciones: histogramas para distribuciones numéricas, barras para categorías, boxplots para dispersión y valores extremos, y diagramas de dispersión para relaciones entre variables numéricas.
8. Correlación: signo e intensidad del coeficiente de Pearson, posibles efectos de valores extremos, limitaciones frente a relaciones no lineales y diferencia entre correlación y causalidad.
9. Interpretación crítica de resultados: conclusiones respaldadas por datos, limitaciones de las evidencias y trazabilidad de los procedimientos realizados.

I. Tipos de datos y perfilamiento

1. Tipos de datos (SECOP II). Localizan la carga del conjunto de datos y la salida de info() o una inspección equivalente. Seleccionen una columna de fecha, una numérica y una categórica que realmente existan en su archivo. Registren el tipo observado para cada una.
    a) ¿El tipo observado es apropiado para el análisis realizado? Expliquen cada caso.

Los tipos de datos indican cómo está almacenada la información y qué operaciones podemos realizar con ella.

Tipo de variable	Ejemplo	Utilidad
Numérica	`valor_del_contrato`	Calcular medias, medianas y dispersión.
Categórica	Tipo de contrato o entidad	Agrupar y comparar registros.
Fecha	Fecha de firma o inicio	Analizar periodos y duraciones.
Identificador	ID del contrato	Reconocer registros, no medir cantidades.

En SECOP II, el notebook revisa los tipos de las columnas y convierte campos de fecha cuando corresponda. Una fecha almacenada como texto puede impedir cálculos temporales correctos.

b) ¿Cuál de las columnas seleccionadas requeriría una comprobación o conversión y por qué?

La columna **`fecha_de_notificaci_n_de_prorrogaci_n`** requiere comprobarse porque una fecha almacenada como texto no permite realizar correctamente operaciones de tiempo. También conviene verificar que **`valor_del_contrato`** no tenga símbolos monetarios, separadores o textos que impidan tratarla como numérica.

c) Identifiquen en el notebook una conversión de tipos, si existe. Si no existe, indiquen una comprobación que aplicarían a una columna concreta

No tenemos evidencia suficiente para afirmar que el notebook realizó una conversión específica. Por eso, la respuesta es: no confirmada en el laboratorio.

Una comprobación que aplicaría sería revisar la columna de fecha y convertirla con **`pd.to_datetime()`**, verificando después cuántos valores no se pudieron interpretar. Así se evita asumir que todos los registros contienen fechas válidas.

2. Perfilamiento (SECOP II o Spotify). Localizan dos operaciones de exploración inicial, por ejemplo info(), describe(), nunique() o equivalentes. Copien un hallazgo concreto de cada salida.
   ¿Qué pregunta distinta responde cada operación? ¿Qué decisión de análisis justificarán con estos hallazgos?

`info()`

- Hallazgo: el conjunto de contratos de SECOP II analizado contiene 50.000 registros y 85 columnas.
- ¿Qué pregunta responde? Permite conocer el tamaño del conjunto, los tipos de datos y la cantidad de valores no nulos por columna.
- ¿Qué decisión justificaría? Identificar variables que requieren conversión de tipos o revisión de valores faltantes antes de hacer cálculos.

Diagnóstico de valores faltantes

- Hallazgo: la columna **`fecha_de_notificaci_n_de_prorrogaci_n`** presenta aproximadamente un 85,41 % de valores faltantes; **`fecha_inicio_liquidacion`**, un 63,51 %.
- ¿Qué pregunta responde? Permite conocer qué columnas tienen información incompleta y en qué proporción.
- ¿Qué decisión justificaría? Evaluar si esas fechas son indispensables para el análisis, si es posible obtenerlas de otra fuente o si conviene limitar el análisis a los registros que cuentan con ellas.

3. Variables de Spotify. Identifiquen en el notebook tres columnas reales: una categórica, una numérica y un identificador, si existe. Escriban sus nombres tal como aparecen en el conjunto de datos.

   En el archivo **`canciones.csv`** se identifican columnas como **`genero`**, **`popularidad`** y **`anio`**. El archivo contiene 2.000 registros y 13 columnas. No se ha confirmado una columna identificadora única de canción.

   a) Clasifiquen las tres columnas y justifiquen su elección.
      - **`genero`**: categórica, porque representa grupos musicales como pop, urbano, rock, electrónica o indie.
      - **`popularidad`**: numérica, porque expresa una puntuación que permite comparar canciones y calcular estadísticas.
      - **`anio`**: numérica con significado temporal, porque representa el año asociado a cada canción. Aunque se almacene como número, su interpretación es temporal.

   b) Si existe un identificador numérico, expliquen por qué no debe analizarse como una medida. Si no existe, aclárenlo.

      No se ha confirmado un identificador único de canción en las columnas disponibles. Si existiera un código numérico, no debería calcularse su media ni interpretarse como una magnitud, ya que su función sería identificar cada registro y no medir una característica musical.

   c) Formulen una pregunta que puedan responder con las columnas seleccionadas y señalan la celda que permitiría comenzar a responderla.

   Una pregunta posible es: ¿cómo varía la popularidad de las canciones según su género y año?

   Para comenzar, se utilizaría la celda del notebook que carga el archivo y permite consultar **`genero`**, **`popularidad`** y **`anio`**. Sin embargo, como no se desarrolló un notebook de Spotify, no podemos indicar un número de celda real. La pregunta puede analizarse con el CSV, pero el resultado no debe atribuirse a una celda inexistente.

II. Calidad y preparación de datos

4. Valores faltantes (SECOP II o Spotify). Localicen el diagnóstico de valores nulos. Seleccionen una columna real y registren el número o porcentaje de faltantes reportado. Si no se evaluaron los faltantes, indíquenlo y expliquen qué instrucción usarían.

   Tomamos como ejemplo la columna **`fecha_de_notificaci_n_de_prorrogaci_n`** de SECOP II, con aproximadamente 85,41 % de valores faltantes.

   a) ¿Qué información de esa columna necesitarán antes de decidir un tratamiento?

      Necesitaría conocer qué representa la fecha, por qué puede faltar, si es obligatoria para todos los contratos y si los valores ausentes se concentran en determinados años, entidades o tipos de contratación. También comprobaría si los faltantes significan que no ocurrió una prórroga o si simplemente no se registró la información.

   b) Para esa columna concreta, comparen las consecuencias de eliminar, imputar o conservar los faltantes.
      - **Eliminar registros:** permite trabajar con fechas disponibles, pero podría reducir demasiado la muestra y generar sesgo si los registros eliminados tienen características particulares.
      - **Imputar fechas**: no sería recomendable asignar una fecha promedio o inventada, porque alteraría la cronología de los contratos y podría crear eventos que nunca ocurrieron.
      - **Conservar los faltantes**: permite mantener los contratos para otros análisis y reconocer que la fecha no está disponible. Para un análisis temporal, habría que excluirlos de los cálculos que requieran una fecha válida o tratarlos de forma explícita.

   c) ¿Por qué asignar cero podría cambiar un resultado de su análisis?

      El cero es un valor, no la ausencia de información. Si se reemplazaran las fechas faltantes por cero, podrían aparecer fechas inválidas o registros artificiales. En una variable monetaria, asignar cero a un contrato cuyo valor se desconoce reduciría artificialmente la media y el total calculado.

5. Duplicados (SECOP II). Busquen si el laboratorio revisó registros duplicados. Identifiquen las columnas utilizadas para reconocerlos, o expliquen cuáles utilizarían si el procedimiento no aparece.

   En el análisis del archivo auxiliar de modificaciones se identificaron 78 filas completamente duplicadas. Después de retirarlas quedaron 49.922 filas. También se encontraron 10 identificadores de evento con atributos en conflicto, lo cual requiere una revisión adicional.

   a) ¿Qué diferencia existe entre filas completamente idénticas y contratos distintos que comparten algunos atributos?

   Una fila completamente idéntica repite todos los valores de otra fila. Puede ser un duplicado accidental.

   En cambio, dos contratos pueden compartir la entidad, la modalidad o incluso un valor similar y seguir siendo contratos válidos diferentes. Por eso, compartir algunos atributos no es suficiente para eliminarlos.

   b) ¿Qué identificador o combinación de campos del archivo permitiría verificar si hay duplicación?

   Primero utilizaría el identificador único del contrato, si está disponible, para comprobar si se repite. Para el archivo de modificaciones, usaría el identificador del contrato junto con el identificador del evento o de la modificación, si ambos existen y representan de forma única cada evento.

   También compararía los registros completos. La combinación exacta debe verificarse en las columnas reales del archivo antes de definirla como clave.

   c) ¿Qué estadística o resultado de su laboratorio podría cambiar si se eliminaran contratos válidos?

      Podrían cambiar el número total de contratos, la distribución por entidad y modalidad, los totales monetarios y las medias de los valores contractuales. Eliminar contratos válidos podría hacer que una entidad o modalidad pareciera tener menos participación de la real.

6. Valores atípicos (SECOP II o Spotify). Seleccionen una variable numérica efectivamente explorada en el laboratorio. Localicen sus cuartiles o el gráfico usado para identificar valores extremos. Si no aparecen cuartiles, indiquen cómo los calcularían para esa misma variable.

   Seleccionamos la variable numérica **`valor_del_contrato`**, porque sus valores muestran una diferencia considerable entre los contratos habituales y los de mayor cuantía.

   a) A partir de los cuartiles de la variable seleccionada, calculen el IQR y los límites de la regla de Tukey. Si el notebook no presenta estos valores, describan el procedimiento sin inventar cifras.

   No tenemos confirmados los cuartiles Q1 y Q3 de **`valor_del_contrato`** en la salida del notebook. Por tanto, no es correcto inventarlos.

El procedimiento sería:

- Calcular Q1, el percentil 25.
- Calcular Q3, el percentil 75.
- Calcular el rango intercuartílico:

$$IQR = Q_3 - Q_1$$

- Calcular los límites de Tukey:

$$L_{inferior} = Q_1 - 1.5(IQR)$$

$$L_{superior} = Q_3 + 1.5(IQR)$$

Los valores por fuera de esos límites se marcarían como posibles valores atípicos.

b) Identifiquen un valor extremo real, si aparece en la salida o gráfico, y expliquen si supera los límites calculados.

En los datos de SECOP II se reportó un valor contractual máximo cercano a **620,8 billones de pesos colombianos**. Es un valor extremo que merece revisión por su magnitud. Sin embargo, al no tener los cuartiles confirmados, no podemos asegurar matemáticamente que supera el límite superior de Tukey.

c) ¿Por qué no sería correcto eliminarlo automáticamente en el contexto del laboratorio?

Porque un valor extremo no necesariamente es un error. Podría corresponder a un contrato real de gran cuantía, a un registro agregado o a un problema de formato. Antes de eliminarlo, habría que verificar el contrato, la unidad monetaria, los separadores numéricos y la fuente original. Si es válido, debe conservarse o analizarse por separado con una justificación clara.

III. Estadística descriptiva y análisis exploratorio

7. Tendencia central y dispersión. Busquen en SECOP II o Spotify una tabla de estadísticas descrip-tivas de una variable numérica.

   Para ilustrar las medidas se utiliza la variable **`popularidad`** de Spotify, cuyos valores se calcularon a partir del archivo CSV disponible. Estos resultados son del archivo, no de un notebook de Spotify.

   a) Registren la variable, su media y su desviación estándar, si están disponibles.

Indicador	**Resultado**
Variable	**`popularidad`**
Media	58,49
Desviación estándar	13,67
Mínimo	11,6
Máximo	100

   b) Expliquen qué aporta cada medida y qué no puede concluirse únicamente con ellas.

   La media de 58,49 indica el promedio de popularidad de las canciones analizadas. La desviación estándar de 13,67 expresa cuánto suelen dispersarse los valores alrededor de esa media.

   Estas medidas no permiten afirmar por sí solas que la distribución sea simétrica, que exista una relación con el género o que una característica musical cause una mayor popularidad. Para eso se necesitan gráficos y análisis adicionales.

c) Localicen un gráfico de esa variable. ¿Qué información añade frente a la tabla?

No se ha confirmado un gráfico de **`popularidad`** en un notebook de Spotify, porque ese notebook no se desarrolló.

Un histograma de **`popularidad`** permitiría observar dónde se concentran las canciones, si hay varios grupos de puntuaciones y si existen valores poco frecuentes. La tabla resume los datos mediante números; el histograma muestra su distribución.

8. Media y mediana. Seleccionen una variable numérica de uno de los laboratorios que tenga media y mediana reportadas, o calculables a partir del notebook.

a) Registren ambos valores y comparen su magnitud.

Para `popularidad` de Spotify:

Medida	**Resultado**
Media	58,49
Mediana	58,85

La mediana es ligeramente superior a la media, con una diferencia aproximada de 0,36 puntos.

b) ¿Qué hipótesis sobre la distribución sugieren esos resultados? ¿Qué gráfico del repositorio permitiría contrastarla?

Que la media y la mediana sean cercanas sugiere que las medidas de tendencia central tienen valores similares. No demuestra, por sí solo, que la distribución sea simétrica.

Un histograma permitiría revisar la forma general de la distribución y un diagrama de caja ayudaría a identificar dispersión y posibles valores extremos. No hay evidencia de que esos gráficos se hayan generado en un notebook de Spotify.

c) Redacten una interpretación limitada a lo que muestran las evidencias; eviten afirmar que conocen la forma exacta de la distribución sin observarla.

La popularidad media de las canciones es 58,49 y la mediana es 58,85. La proximidad entre ambos valores indica que el centro de la distribución es parecido según estas dos medidas. Para describir su forma con mayor precisión, sería necesario observar un histograma o un diagrama de caja.

IV. Visualización y correlación

9. Elección de gráficos. Localicen dos visualizaciones diferentes en SECOP II o Spotify.

La guía solicita dos visualizaciones efectivamente desarrolladas en uno de los laboratorios. No contamos con evidencia suficiente para identificar dos gráficos concretos, con sus nombres de archivo y hallazgos, en los notebooks de SECOP II o Spotify. Por ello, las siguientes son propuestas de aplicación y no resultados visuales ya obtenidos.

a) Indiquen el nombre del archivo, las variables representadas y el tipo de gráfico.
   - Visualización 1 propuesta: histograma de **`popularidad`**, a partir de **`canciones.csv`**. Representaría la frecuencia de canciones en diferentes intervalos de popularidad.
   - Visualización 2 propuesta: diagrama de dispersión de **`energia`** frente a **`popularidad`**, también a partir de **`canciones.csv`**. Cada punto representaría una canción.

b) ¿Qué pregunta permite responder cada gráfico? Describan un hallazgo concreto.
   - El histograma permitiría responder: ¿en qué intervalos se concentra la popularidad de las canciones? Como evidencia disponible, la media es 58,49 y la mediana 58,85. Sin el histograma, no es posible afirmar en qué intervalo se concentra la mayoría.
   - El diagrama de dispersión permitiría responder: ¿se observa alguna asociación entre energía y popularidad? No se ha calculado ni confirmado un patrón concreto de esta relación, así que no sería correcto afirmar que es positiva o negativa.

c) Propongan una visualización alternativa para una de esas preguntas y expliquen qué información adicional aportaría.

Para comparar la popularidad entre géneros, utilizaría un diagrama de caja (boxplot) por `genero`. Este mostraría la mediana, los cuartiles, la dispersión y los posibles valores extremos de cada género. Complementaría el histograma porque permitiría comparar grupos, en lugar de observar únicamente la distribución general.

10. Correlación. Localicen en uno de los laboratorios una matriz de correlación, un coeficiente de Pearson o un análisis de relación entre variables numéricas.

    a) Identifiquen las dos variables y el coeficiente observado, si está disponible. Si no se calculó, indiquen qué dos variables reales examinarían.

    No se ha confirmado una matriz de correlación ni un coeficiente de Pearson calculado en el laboratorio de Spotify. Examinará las variables reales **`energia`** y **`popularidad`** para estudiar si existe una relación lineal entre la energía de las canciones y su popularidad.

    b) Expliquen el signo y la intensidad de la relación lineal. ¿Por qué un coeficiente cercano a cero no descarta cualquier relación?

    El coeficiente de Pearson r toma valores entre -1 y 1:

    - Un valor positivo indica una asociación lineal positiva.
    - Un valor negativo indica una asociación lineal negativa.
    - Un valor cercano a cero indica poca o ninguna asociación lineal.

    Un coeficiente cercano a cero no descarta cualquier relación porque las variables podrían estar relacionadas de forma no lineal. Además, valores extremos pueden influir en el coeficiente y modificar su interpretación.

    c) ¿Por qué el resultado no permite afirmar que una variable causa cambios en la otra?

    La correlación describe una asociación, no demuestra causalidad. Sí energía y popularidad estuvieran correlacionadas, eso no probaría que la energía produce cambios en la popularidad. Podrían intervenir otras variables, como el género, el año o las estrategias de promoción. Para establecer causalidad se necesitaría un diseño de investigación adecuado y evidencia adicional.

11. Revisión crítica de una visualización. Elijan un diagrama de dispersión o una visualización que permita examinar la relación entre variables. Si no existe en el repositorio, identifiquen las columnas con las que lo construirían.

    a) ¿Qué patrón puede observarse realmente? Distingan observación de interpretación.

    No hay un diagrama de dispersión confirmado de **`energia`** frente a **`popularidad`** en el laboratorio de Spotify. Por lo tanto, no se puede describir un patrón visual real.

    Al construirlo, la observación consistiría en describir cómo se distribuyen los puntos. La interpretación sería explicar qué podría significar ese patrón, sin confundir una asociación visible con una relación causal.

b) ¿Existen puntos extremos o agrupaciones que puedan afectar la lectura del gráfico?

Sin el gráfico no podemos confirmar agrupaciones ni puntos extremos en esa relación. Al construirlo, se revisaría si hay canciones con valores muy alejados del resto, concentraciones de puntos y diferencias entre géneros. También se comprobaría si unos pocos registros influyen de manera desproporcionada en la tendencia aparente.

c) Escriban una conclusión que no exceda la evidencia disponible.

El archivo **`canciones.csv`** contiene variables que permiten examinar una posible relación entre energía y popularidad, pero esa correlación no ha sido confirmada. Se requiere generar y revisar el diagrama de dispersión y calcular el coeficiente correspondiente antes de concluir si existe una asociación lineal.

V. Análisis crítico aplicado

12. Trazabilidad de un resultado. Seleccionen un resultado relevante del laboratorio de SECOP II o Spotify (tabla, estadística o gráfico) y reconstruyan cómo se obtuvo.

Para esta pregunta seleccionamos el resultado descriptivo de la popularidad en Spotify: media de 58,49. La cifra se obtuvo a partir del CSV disponible, pero no de un notebook de Spotify.

a) Identifiquen el notebook y las celdas de carga, transformación y obtención del resultado.

No se desarrolló un notebook de Spotify, así que no hay números de celdas que podamos identificar.

La trazabilidad del cálculo se reconstruiría de la siguiente manera:

1. Carga: leer **`canciones.csv`** en un **`DataFrame`**.
2. Comprobación: verificar que **`popularidad`** exista y sea numérica, además de revisar los valores faltantes.
3. Cálculo: obtener la media de la columna **`popularidad`**.
4. Resultado: registrar el valor calculado y documentar el archivo utilizado.

En SECOP II sí se trabajó con un notebook, pero para este ejemplo no sería correcto atribuir el resultado de Spotify a ese archivo.

b) ¿Qué columnas se utilizaron y qué decisiones de preparación influyeron en el resultado?

Se utilizó la columna **`popularidad`** de **`canciones.csv`**. La media depende de los registros incluidos y de cómo se manejan los valores faltantes, los tipos incorrectos y los posibles valores extremos. Antes de interpretar el resultado, hay que confirmar que los valores sean numéricos válidos y que la población de canciones analizada corresponda al objetivo del estudio.

c) ¿Qué pregunta analítica responde? Redacten una conclusión sustentada en un dato o patrón concreto.

Responde a la pregunta: ¿cuál es la popularidad promedio de las canciones del archivo?

La media calculada es 58,49 puntos y la mediana es 58,85 puntos. Esto describe el centro de los valores de popularidad en el conjunto analizado, pero no demuestra qué características hacen que una canción sea más popular.

d) Señalen una limitación de esa conclusión y una comprobación adicional que realizarían.

La limitación es que una media general no muestra las diferencias entre géneros, años ni características musicales. Además, el resultado corresponde al archivo disponible y no necesariamente representa todas las canciones de Spotify.

Como comprobación adicional, compararía la popularidad por **`genero`** y **`anio`**, revisaría la distribución con un histograma y comprobaría si existen valores extremos que influyan en las estadísticas.